

HW1: 三层神经网络分类器

1. 实验概述

1.1 数据集介绍

EuroSAT 数据集包含 27,000 张 64×64 的 RGB 卫星遥感图像，分为 10 个地表覆盖类别：

类别	样本数	类别	样本数
AnnualCrop（一年生作物）	3000	Pasture（牧场）	2000
Forest（森林）	3000	PermanentCrop（多年生作物）	2500
HerbaceousVegetation（草本植被）	3000	Residential（居民区）	3000
Highway（公路）	2500	River（河流）	2500
Industrial（工业区）	2500	SeaLake（海/湖）	3000

数据划分: 70% 训练集（18900）、15% 验证集（4050）、15% 测试集（4050）。

1.2 数据预处理

对图像进行以下预处理：

- 像素值归一化到 $[0, 1]$ （除以 255）
- Per-channel 标准化（减去训练集均值，除以训练集标准差）
 - R 通道: $\text{mean}=0.345, \text{std}=0.203$
 - G 通道: $\text{mean}=0.380, \text{std}=0.137$
 - B 通道: $\text{mean}=0.408, \text{std}=0.116$
- 展平为一维向量: $(64, 64, 3) \rightarrow (12288,)$

2. 模型结构

2.1 网络架构

基础版（v1）：

Input(12288) → Linear(512) → ReLU → Linear(256) → ReLU → Linear(10) → Softmax

改进版（v2）：

Input(12288) → Linear(1024) → ReLU → Dropout(0.4) → Linear(512) → ReLU → Dropout(0.4) → Linear(10) → Softmax

2.2 核心组件

激活函数：实现了三种激活函数，支持前向和反向传播：

- ReLU: $f(x) = \max(0, x)$, 梯度 = 1 if $x > 0$ else 0
- Sigmoid: $f(x) = 1/(1+\exp(-x))$, 梯度 = $f(x)(1-f(x))$
- Tanh: $f(x) = \tanh(x)$, 梯度 = $1 - f(x)^2$

根据激活函数自动选择初始化: ReLU 用 He init, Sigmoid/Tanh 用 Xavier init。

损失函数：Softmax + Cross-Entropy Loss（合并计算保证数值稳定）。前向时先减去 logits 最大值防止溢出，再计算 softmax 概率和交叉熵。

优化器：

- SGD with Momentum: $v = 0.9 \cdot v + (dW + \text{weight_decay} \cdot W)$; $W \leftarrow lr \cdot v$
- Weight Decay 只作用于权重 W，不作用于偏置 b
- WarmupMultiStepLR: 前 5 epoch 线性 warmup，之后在 milestone 处 $lr \times \text{gamma}$

3. 训练过程与结果

首先使用 v1 基础配置进行训练，发现严重的过拟合问题（训练准确率 97% vs 验证准确率 65%）。分析原因后，在 v2 中针对性地加入了 Dropout、更强的 Weight Decay 和数据增强来解决。

3.1 训练配置对比

参数	v1（基础版）	v2（改进版）
隐藏层大小	512 / 256	1024 / 512
学习率	0.01	0.01
Momentum	0.9	0.9
Weight Decay	1e-4	5e-3
Dropout	无	0.4
数据增强	无	随机水平翻转
Epochs	50	80
LR Milestones	[30, 40]	[40, 60]
LR Gamma	0.1	0.1

3.2 训练曲线（v1 基础版）




图 1: v1 基础版训练曲线（左: Loss, 右: Accuracy）

3.3 训练曲线（v2 改进版）




图 2: v2 改进版训练曲线 (左: Loss, 右: Accuracy)

分析：

- v1: 训练准确率 97%，验证准确率 65.5%，严重过拟合 (gap=32%)。验证 Loss 从 epoch 11 开始持续上升 (1.26 → 2.03)。
- v2: 训练准确率 81%，验证准确率 70.4%，过拟合显著改善 (gap=11%)。验证 Loss 稳定收敛。

4. 测试结果

4.1 总体准确率

- v1 基础版测试准确率: 64.89% (2628/4050)
- v2 改进版测试准确率: 68.91% (2791/4050)
- 提升: +4.02 个百分点

4.2 混淆矩阵 (v2)




图 3: v2 改进版归一化混淆矩阵

4.3 各类别准确率（v2）

类别	准确率	正确/总数
Forest	88.37%	395/447
Industrial	87.11%	331/380
SeaLake	77.00%	365/474
Pasture	74.25%	199/268
Residential	67.67%	291/430
River	65.48%	275/420
AnnualCrop	65.38%	287/439
HerbaceousVegetation	60.32%	263/436
PermanentCrop	59.42%	227/382
Highway	42.25%	158/374

5. 权重可视化

将第一层 Linear 的权重矩阵的每一列（对应一个神经元）恢复为 $64 \times 64 \times 3$ 的图像形式进行可视化。每个神经元学习到了不同的颜色和空间模式。

First Hidden Layer Weight Visualization




图 4: v1 第一隐藏层权重可视化




图 5: v2 第一隐藏层权重可视化

观察与讨论：

- 部分神经元呈现明显的绿色倾向，可能对应森林、草地等植被类别的特征提取
- 部分神经元呈现蓝色/深色模式，可能对应水体（河流、湖泊）的特征
- 部分神经元呈现亮色/黄色模式，可能对应裸土或农作物区域
- v2 的权重模式比 v1 更加多样化，这与其更大的隐藏层维度一致

6. 错例分析

6.1 主要错误类型

排名	真实类别	预测类别	错误数
1	HerbaceousVegetation	PermanentCrop	62
2	River	Highway	61
3	AnnualCrop	PermanentCrop	55
4	SeaLake	Forest	54
5	Highway	River	52

6.2 错误原因分析

1. River 与 Highway 互相混淆（共 113 例）：

两者在卫星图像中都表现为"带状结构穿过画面"。MLP 将图像展平后完全丢失了空间结构信息，只能依赖全局颜色统计来区分，而两者颜色差异不大（都偏暗灰色调）。

2. HerbaceousVegetation 与 PermanentCrop 互相混淆（共 97 例）：

两者都是植被覆盖的地表，颜色特征接近。区别在于 PermanentCrop 通常有规则的种植纹理（如果园、葡萄园），而 HerbaceousVegetation 是自然草地。这种纹理差异需要局部空间特征才能捕捉。

3. AnnualCrop 与 PermanentCrop 混淆（55 例）：

两者都是农作物，颜色极其相似（偏黄绿色调），区别主要在种植模式（一年生 vs 多年生），在低分辨率卫星图上视觉差异很小。

4. SeaLake 与 Forest 互相混淆（共 90 例）：

两者都是深色区域。Forest 整体更暗，SeaLake 稍微偏蓝。当森林图像特别暗或湖泊图像有大量岸边植被时，颜色统计会趋同。

5. Highway 准确率最低（42.25%）：

Highway 的平均颜色接近数据集均值，说明其颜色特征不突出。道路本身是灰色的，但周围环境可能是农田、草地、建筑等，导致整体颜色统计取决于周围地物而非道路本身。

6.3 根本原因总结

- MLP 无法利用空间结构：展平为一维向量后，带状结构（河流/公路）、纹理模式（作物类型）等空间信息完全丢失
- 颜色相似的类别难以区分：仅靠全局颜色统计无法区分视觉相似的类别
- 类内方差大：Highway 等类别周围环境多变，同类图像特征分布很散
- 分辨率限制：64×64 的图像中细节有限

这些问题是 MLP 架构的固有局限，CNN 通过卷积核提取局部空间特征可以有效解决。

6.4 错例可视化




图 6: 分类错误样本示例

7. 超参数探索

v1 训练后发现严重过拟合，因此在 v2 中逐步调整超参数来解决这个问题。以下是各超参数调整的效果：

1. 隐藏层大小 (512/256 $\rightarrow$ 1024/512)：更大的隐藏层提供了更强的表达能力。单独增大隐藏层会加剧过拟合，但配合正则化后反而能提升性能。
2. Weight Decay ($1e-4 \rightarrow 5e-3$)：v1 的 $1e-4$ 正则化强度明显不足，将其提高 50 倍后有效抑制了权重过大的问题。
3. Dropout (0 $\rightarrow$ 0.4)：这是解决过拟合最有效的手段，将 Train-Val gap 从 32% 缩小到 11%。
4. 数据增强 (无 $\rightarrow$ 随机水平翻转)：卫星图像水平翻转后语义不变，这种简单的增强增加了训练数据多样性。
5. 学习率策略 (WarmupMultiStepLR)：前 5 个 epoch 线性 warmup 避免了训练初期因动量累积导致的 loss 爆炸，milestone 处降低学习率帮助后期精细收敛。

8. 总结

本实验使用 NumPy 从零实现了三层 MLP 分类器，在 EuroSAT 遥感图像数据集上进行了完整的训练、评估和分析。

主要成果：

- 手动实现了完整的自动微分和反向传播系统
- 实现了 SGD (带动量)、WarmupMultiStepLR、Cross-Entropy Loss、L2 正则化
- 支持 ReLU、Sigmoid、Tanh 三种激活函数
- 基础版达到 64.89% 测试准确率，改进版达到 68.91%
- 通过 Dropout + 数据增强 + 更强正则化有效解决了过拟合问题

遇到的问题与解决：

- v1 严重过拟合 (train 97% vs val 65%) $\rightarrow$ 加入 Dropout(0.4) + 增大 weight_decay 到 $5e-3$
- 训练初期 loss 爆炸 $\rightarrow$ 加入 warmup 策略，前 5 epoch 线性增长学习率
- per-channel 均值计算精度问题 (float32 大数组累加) $\rightarrow$ 改用 float64 分通道计算

局限性与改进方向：

- MLP 无法利用图像的空间结构信息，是性能瓶颈的根本原因
- 使用 CNN 架构可以显著提升分类准确率
- 更复杂的数据增强 (旋转、颜色抖动) 可能进一步提升泛化能力